AviRonda: assistente de ambiente de aviário com LLM local (RAG)

Global Solution 2026.2 · FIAP · Engenharia de Software 4º ano · Componente: Inteligência (Generative AI for Engineering)

Repositório: https://github.com/Matheus-Zanardi/Avironda

Integrantes

Integrante	RM
David Denunci	RM98603
Fernando Popolili	RM99919
Lucas de Toledo	RM97913
Matheus Zanardi	RM98832
Augusto Milreu	RM98245

1. Ficha Técnica

- **Cidadão e território:** produtor avícola, com foco em aviários de frango de corte.
- **Problema, em uma frase:** calor e amônia no ambiente do aviário prejudicam a saúde das aves e o desempenho, e o produtor precisa de informação confiável para agir.
- **Proposta de valor:** assistente que responde perguntas sobre o ambiente do aviário com base em fontes técnicas, citando a fonte ou recusando quando a informação não consta.
- **Arquitetura:** embeddings (BAAI/bge-small-en-v1.5), ChromaDB como base vetorial, LLM local (qwen2.5:3b via Ollama) e um agente que reformula a pergunta.
- **Fontes de dados:** Embrapa, aviNews, Exame Agro, A Gazeta, UFSM, UNICAMP e anais de congresso (16 trechos).
- **Modelos de IA:** qwen2.5:3b (geração) e bge-small-en-v1.5 (embeddings).
- **URL e repositório:** https://github.com/Matheus-Zanardi/Avironda
- **Indicadores de impacto:** taxa de acerto nas perguntas de teste e taxa de recusa correta quando a informação não consta na base.
- **ODS conectados:** ODS 2, 3 e 9.

2. Diagrama do pipeline

O diagrama está no README do repositório. Fluxo: pergunta → embedding → busca no ChromaDB → verificação de distância (limiar 0,20) → recusa, ou contexto com os 3 melhores trechos → LLM → resposta com citação.

3. Tabela da base

Fonte	Formato	Licença	Trechos
Embrapa (amônia, dark house, cama reutilizada, estresse calórico)	Artigos e comunicados (PDF)	Verificar no site da Embrapa	9
aviNews	Notícia (HTML)	Direitos reservados ao site	2
Exame Agro	Notícia (HTML)	Direitos reservados ao site	1
A Gazeta	Artigo de opinião (HTML)	Direitos reservados ao site	1
UFSM	Dissertação (PDF)	Acesso aberto, verificar	1
UNICAMP	Resumo de congresso (PDF)	Verificar	1
Anais de congresso (Sousa-PB)	Artigo (PDF)	Verificar	1
Total			**16**

4. Metodologia

1. **Base:** trechos curtos, cada um com id, fonte, título, URL e texto. Não se incluiu informação que a fonte não traz.
2. **Casos de teste:** 11 perguntas em `avaliacao/casos.jsonl`, com resposta esperada e fonte esperada. Uma delas (c04) tem resposta "não consta".
3. **Três configurações comparadas:** LLM sem contexto, RAG simples e agente (reformula a pergunta e faz duas buscas).
4. **Recall:** recall@1 e recall@3 medidos sobre os 10 casos com resposta na base.
5. **Limiar de recusa:** distância máxima de 0,20 do melhor trecho.

5. Resultados

Configuração	Acertos (10 casos automáticos)	Observação
Sem contexto	1	Acerta só o c08, por acaso
RAG simples	9	Erro: c03 (resposta incompleta)
Agente	9	Mesmo erro: c03

- **c05** (efeitos do El Niño) é avaliado à mão e teve o mesmo resultado nas três configurações.
- **Recall@1 = 1,00 e recall@3 = 1,00** nos 10 casos com resposta na base.
- **Limiar:** as menores distâncias dos casos respondíveis ficaram entre 0,10 e 0,20. Fixado em 0,20. O caso c04 ("não consta") tem distância 0,175, menor que a de alguns casos respondíveis. Por isso, o limiar sozinho não separa os casos, e a recusa depende também do modelo gerador.

6. Erros encontrados e correções

#	Configuração	Caso	O que aconteceu	Causa	Correção
1	Sem contexto	c01	Não conhece o limite de 20 ppm para exportadores	Falta de conhecimento específico	RAG com base da Embrapa
2	Sem contexto	c02	Inventa valores (20 e 10 ppm) e atribui à Embrapa	Alucinação com atribuição de fonte	Responder só com trechos recuperados e citar o id
3	Sem contexto	c04	Inventa limite de CO2 (10%) e faixa de umidade	Alucinação em pergunta sem resposta na base	Recusa "não consta na base"
4	RAG (versão 1)	c06	Respondeu 20 ppm (exportadores) em vez de 25 ppm (Embrapa)	Conflito entre fontes sem critério de escolha	Prompt pede usar a fonte citada na pergunta; corrigido
5	RAG (versão 2)	c03	Respondeu só 36 ppm, quando a pergunta pede 29, 78 e 36	Prompt de "uma frase" limita respostas com listas	Não corrigido. Proposta: pedir a lista completa de valores

Observação: o ajuste do item 4 mudou o comportamento do item 5. Cada ajuste de prompt corrigiu um caso e afetou outro, por isso a versão final ficou com o erro do c03 documentado.

7. Conclusão técnica

Sem contexto, o modelo de 3B parâmetros erra em 9 de 10 casos avaliáveis e inventa números com atribuição a fontes reais. O RAG simples corrige esse comportamento: 9 de 10, com recall perfeito na busca, e recusa correta quando a informação não consta. O agente, que reformula a pergunta e faz duas buscas, não superou o RAG simples nesse conjunto de teste.

As limitações são: conjunto de teste pequeno (11 casos), base pequena (16 trechos), perguntas com termos próximos dos trechos (o que favorece o recall), e limiar de distância que não separa sozinho a recusa. Como próximos passos, ampliar a base e o conjunto de teste com perguntas que exijam juntar fontes, e substituir a instrução de "uma frase" por um formato de resposta que aceite listas.